

Двунаправленный переводчик РЖЯ “Glossa”

Черных А.В

ML-инженер NOEMA (DSR, г. Воронеж)



01. Введение

Проблема

- 430 млн человек в мире имеют нарушения слуха (ВОЗ, 2023)
- В России – более 13 млн; для значительной части РЖЯ является родным языком
- Дефицит сурдопереводчиков в России превышает 4 000 человек
- К 2050 году потерей слуха будет страдать каждый десятый житель планеты

Целевая аудитория и альтернативы

01

Пользователи РЖЯ

02

Слышащие собеседники
(родственники, персонал)

03

Институции (поликлиники,
МФЦ, контакт-центры)

Альтернативы

Решение	Недостаток
«Сурдофон»	300 жестов, нет двунаправленности
«Сурдосервер»	Перевод оператором-человеком, не автоматический
SignAll, Signapse	Только ASL, не поддерживают РЖЯ
Академические системы	Требуют Kinect / RealSense, спец. перчатки

Отличие Glossa

**Расширяемый двусторонний перевод
в реальном времени с обычной веб-
камеры, без посредника**

Дорожная карта развития проекта

Сентябрь - Октябрь

- Изучение РЖЯ и аналогов
- Постановка требований и SLO
- Проектирование архитектуры системы

Ноябрь - Декабрь

- Загрузка корпуса Slovo
- Извлечение скелетных точек
- Обучение ST-GCN и валидация

Январь - Март

- Пять микросервисов на FastAPI
- Оптимизация инференса (ONNX+OpenVINO)
- MLOps: DVC, MLflow, Docker

Апрель - Июль

- Развёртывание на VM-стенде
- CI/CD и написание тестов
- Защита ВКР и публикация

Было (ВКР)


- Пайплайн спроектирован, метрики – расчётные (dry-run по архитектурным характеристикам моделей), не измерены на реальном инференсе
- Скользящее окно фиксированного размера, без автоматической сегментации жеста
- Перевод жест → текст пословный, без накопления в предложение и без учёта контекста диалога
- GPU-путь не проверялся на реальном оборудовании

Стало (текущее состояние)


- Автоматическая сегментация непрерывного видео на жесты (state machine)
- Накопление нескольких жестов в предложение + LLM-дизамбигуация с учётом контекста диалога
- Обратный перевод строго ограничен реальным словарём (детерминированный фильтр)
- Добавлены: загрузка видео, голосовой ввод, двусторонний звонок
- Реальная валидация на живом VM-стенде: измеренная ассурасу, измеренная задержка CPU/GPU, найдены и исправлены реальные регрессии по боевым логам

02. Архитектура проекта

Архитектура системы




Pipeline: РЖЯ → Текст



Сегментация жеста



GestureSegmenter — детальная state machine



ST-GCN — архитектура сети (основа классификатора)


ST-GCN — полная архитектура (реальная конфигурация из train_gesture.py)

Один ST-GCN блок — Graph Conv + Temporal Conv + residual



ST-GCN — граф суставов

- Тело (33) + левая кисть (21) + правая кисть (21) = 75 узлов
- Единая нормализованная матрица смежности для всех 10 блоков
- Свёртка идёт по графу суставов, а не по пикселям кадра — архитектура, осознанно подобранная под skeleton-данные



Накопление предложения и LLM-дизамбигуация


- Не берём жёстко top-1 каждого жеста по отдельности
- LLM выбирает наиболее связную комбинацию top-3 кандидатов сразу по всей последовательности, с учётом истории диалога

Накопление предложения и T9-дизамбигуация



Pipeline: Текст → РЖЯ

- Перевод строго ограничен реальным 200-словным словарём (RAG-lite: лексический предфильтр + few-shot + детерминированный пост-фильтр)
- Вывод — склейка эталонных видео либо skeleton-анимация




03. Данные, эксперименты и метрики

Данные и препроцессинг


Датасет Slovo, осознанно выбрано подмножество 200 классов для MVP (полный корпус ~1000 классов проверен экспериментально отдельно)

- Нормализация относительно плеч/бёдер (инвариантность к росту/дистанции)
- DTW-выравнивание к единому окну — вместо линейной передискретизации



Данные и препроцессинг

```
=== EDA — Slovo RSL ===
Всего записей:      4000
Уникальных жестов:   200
Уникальных дикторов: 154
Train:              3000
Val:                 1000
Средняя длина:       52.3 кадров
Медиана:              49 кадров
P25:                  41 кадров
P50:                  49 кадров
P75:                  60 кадров ← TARGET_FRAMES=64 покрывает это с запасом
P95:                  84 кадров
Дисбаланс классов:   1.0x
```



Эксперименты и метрики

```
🔗 Связаны узлы лица с носом (узел 0)
Компонент связности: 1

Узлов V      : 75
Рёбер E      : 166
Плотность    : 0.043
Self-loops   : 75.0 (ожидается 75)
Компонент связности: 1
✅ Граф связный
✅ Изолированных узлов: 0


Партиционная матрица: (3, 75, 75)
root sum     : 26.7
centripetal sum: 24.9
centrifugal sum: 21.4
=====
✅ Граф готов для ST-GCN с DWPose!

📄 Сводка по графу:
A_np shape:      (75, 75)
A_partition_np shape: (3, 75, 75)
skeleton_graph keys: ['num_nodes', 'edges', 'adjacency_matrix', 'num_edges']
✅ Все переменные определены!
```

Эксперименты и метрики

Тор-1 accuracy: ~60% на 200 классах, held-out валидация (n=1000).

Случайный baseline – 0.5%



Эксперименты и метрики

ВЫВОДЫ

КЛЮЧЕВЫЕ РЕЗУЛЬТАТЫ ЭКСПЕРИМЕНТА:

1. Базовая модель ST-GCN показала F1 = 47.26%
2. Новая модель (Optuna HPO + on-the-fly аугментация) достигла F1 = 61.01%
3. Улучшение составило +13.75 процентных пункта

ГИПОТЕЗА ПОДТВЕРЖДЕНА:

- On-the-fly аугментация позволяет модели видеть больше вариаций данных
- Optuna-поиск гиперпараметров эффективнее ручного подбора
- Комбинация методов дает статистически значимое улучшение

СРАВНИТЕЛЬНАЯ ТАБЛИЦА:

Метрика	Baseline	Новая модель	Изменение
Val Accuracy	47.70%	61.42%	+13.72%
Val F1	47.26%	61.01%	+13.75%
Эпохи	47.26%	164	

Эксперименты и метрики

```
Загрузка данных:
[train] X=(3000, 64, 75, 3) y=(3000,) классов=200
[val] X=(1000, 64, 75, 3) y=(1000,) классов=200
Удаление проблемных видео (динамически найдено, не хардкод):
train: найдено 3 видео с inf в координатах
val: найдено 2 видео с inf в координатах
После очистки: train=2997 (удалено 3), val=998 (удалено 2)

Обрезка выбросов до нормализации...
Обрезано до [-10.0, 10.0]
train min: -10.0000, max: 10.0000
val min: -10.0000, max: 10.0000

Нормализация данных (Z-score)...
mean=[1.222607135772705, 0.534925103187561, 0.8378573656082153]
std =[2.4598872661590576, 3.6632885932922363, 0.3508506119251251]
после нормализации: mean=0.0001, std=1.0295
train min: -4.5622, max: 3.5682
val min: -4.5622, max: 3.5682
✅ Статистика нормализации сохранена: /content/drive/MyDrive/glossa/models/norm_stats.npz
Загружено названий классов: 200

Аугментация (отражение): отражено 1483 / 2997 примеров
Аугментация (spatial jitter): добавлено 1521 / 2997 примеров (σ=0.02)
Аугментация (temporal warp): добавлено 898 / 2997 примеров (max_scale=0.15)
...
Random scaling: 905 (30.2%)
Cutout: 441 (14.7%)
=====
✅ Данные готовы к обучению
```

Эксперименты и метрики

```
Загрузка данных:
[train] X=(3000, 64, 75, 3) y=(3000,) классов=200
[val] X=(1000, 64, 75, 3) y=(1000,) классов=200
Удаление проблемных видео (динамически найдено, не хардкод):
train: найдено 3 видео с inf в координатах
val: найдено 2 видео с inf в координатах
После очистки: train=2997 (удалено 3), val=998 (удалено 2)

Обрезка выбросов до нормализации...
Обрезано до [-10.0, 10.0]
train min: -10.0000, max: 10.0000
val min: -10.0000, max: 10.0000

Нормализация данных (Z-score)...
mean=[1.222607135772705, 0.534925103187561, 0.8378573656082153]
std =[2.4598872661590576, 3.6632885932922363, 0.3508506119251251]
после нормализации: mean=0.0001, std=1.0295
train min: -4.5622, max: 3.5682
val min: -4.5622, max: 3.5682
✅ Статистика нормализации сохранена: /content/drive/MyDrive/glossa/models/norm_stats.npz
Загружено названий классов: 200

Аугментация (отражение): отражено 1483 / 2997 примеров
Аугментация (spatial jitter): добавлено 1521 / 2997 примеров (σ=0.02)
Аугментация (temporal warp): добавлено 898 / 2997 примеров (max_scale=0.15)
...
Random scaling: 905 (30.2%)
Cutout: 441 (14.7%)
=====
✅ Данные готовы к обучению
```

Эксперименты и метрики

ДИАГНОСТИКА ДАННЫХ И ГРАФА СКЕЛЕТА

1. ДИАГНОСТИКА ДАННЫХ



X_train_norm:
shape: (2997, 64, 75, 3)
mean: 0.0001
std: 1.0295
min: -4.5622
max: 3.5682
nan: False
inf: False

X_val_norm:
shape: (998, 64, 75, 3)
mean: 0.1081
std: 1.0071
min: -4.0000
max: 3.5682


Распределение классов:
train: 200 классов, мин=14, макс=15, сред=15.0
val: 200 классов, мин=4, макс=5, сред=5.0
...

Объясненная дисперсия: 0.6824
PC1: 59.11%
PC2: 9.13%


Output is truncated. View as a [scrollable element](#) or open in a [text editor](#). Adjust cell output settings...




Эксперименты и метрики (Граф скелета)






Эксперименты и метрики





Эксперименты и метрики



Эксперименты и метрики



Эксперименты и метрики



04. Инфраструктура, демонстрация, импакт


MLOps-пайплайн

ML-пайплайн: данные → модель → деплой




Применение ИИ-агентов

- Итеративная отладка напрямую по реальным логам с боевого VM
- AI-агент: диагноз первопричины → точечный фикс → регрессионный тест → редеплой → новый реальный прогон
- Так найдено и исправлено 6+ реальных production-регрессий за время эксплуатации (не гипотетических, а по факту живого использования)



MVP (демонстрация видео)



Импакт

Екатерина Нагорная, студентка ВГМУ им. Н.Н. Бурденко, волонтер Воронежского регионального отделения Общероссийской общественной организации инвалидов «Всероссийское общество глухих» (ВОГ):

«Проект решает действительно востребованную задачу – технология уже сейчас способна помочь в реальных коммуникативных ситуациях. По итогам демонстрации мы видим практическую ценность решения, особенно в контексте повседневного общения, где переводчик-человек часто недоступен. Для дальнейшего развития особенно важно расширение словарной базы и доработка пользовательского интерфейса, что позволит сделать продукт более доступным и удобным для ежедневного использования. Рекомендуем продолжить работу в тесном взаимодействии с сообществом пользователей РЖЯ для проверки корректности жестов и адаптации системы под реальные сценарии использования».

Дальнейшее развитие

- Расширение словаря (полный корпус уже проверен экспериментально)
- Дактилология как fallback для слов вне словаря
- Доработка UI по итогам тестирования
- Пилоты с институтами

