

МИНОБРНАУКИ РОССИИ
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ БЮДЖЕТНОЕ ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ
ВЫСШЕГО ОБРАЗОВАНИЯ
«ВОРОНЕЖСКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ»
(ФГБОУ ВО «ВГУ»)

Факультет компьютерных наук

Кафедра технологий обработки и защиты информации

*Разработка многокомпонентной системы двунаправленного перевода
русского жестового языка с применением методов глубокого обучения*

Бакалаврская работа

09.03.02 Информационные системы и технологии

Профиль «Обработка информации и машинное обучение»

Зав. кафедрой: Сирота А. А. д.т.н., профессор

Обучающийся: Черных А. В., студент 4 к. ФКН ИСИТ ОИМО

Руководитель: Дрюченко М. А. к.т.н., доцент

Воронеж 2026

Актуальность

Проблема

- 430 млн человек в мире имеют нарушения слуха (ВОЗ, 2023)
- В России — более 13 млн; для значительной части РЖЯ является родным языком
- Дефицит сурдопереводчиков в России превышает 4 000 человек
- К 2050 году потерей слуха будет страдать каждый десятый житель планеты

Существующие решения и их недостатки

Решение	Недостаток
«Сурдофон»	≈300 жестов, нет двунаправленности
«Сурдосервер»	Перевод оператором-человеком, не автоматический
SignAll, Signapse	Только ASL, не поддерживают РЖЯ
Академические системы	Требуют Kinect / RealSense, спец. перчатки

Вывод: открытой системы двунаправленного автоматического перевода РЖЯ не реализовано

Цель и задачи

Цель: разработать систему Glossa — многокомпонентный программный комплекс двунаправленного перевода РЖЯ в режиме real-time

Целевые показатели (SLO):

Компонент	Метрика	Порог
Классификатор жестов	Тор-1 ассурасу	$\geq 0,90$
Классификатор жестов	F1-weighted	$\geq 0,88$
Классификатор жестов	P95 задержка (CPU)	≤ 50 мс
ASR	WER	$\leq 0,15$
NLP (перевод)	BLEU-4	$\geq 0,35$
NLP	P95 задержка	≤ 500 мс
Система целиком	E2E P95 (Росо М5, 4G)	≤ 2000 мс

Ключевые задачи:

- 1. Анализ методов и выбор архитектурных решений
- 2. Проектирование микросервисной системы
- 3. Обучение классификатора жестов на корпусе Slovo (1000 классов)
- 4. Интеграция LLM с LoRA и RAG для перевода глосс
- 5. Экспериментальное обоснование всех ключевых решений (9 экспериментов)
- 6. Разработка MLOps-инфраструктуры

Корпус Slovo и предметная область

РЖЯ — самостоятельный язык, независимый от русского: своя грамматика, синтаксис, использование трёхмерного пространства жестикуляции

Датасет Slovo (SberDevices, 2023) — первый крупный открытый корпус РЖЯ:

Характеристика	Значение
Число классов жестов	1 000
Всего видеозаписей	20 400
Записей на класс (train/val)	15 / 5
Число дикторов	194
Средняя длина жеста	50,7 кадра ($\sigma = 21,4$)
P75 длины жеста	58 кадров
Разрешение видео	640×480 или 1280×720, 25 FPS
Полнота ключевых точек	87,3% кадров (оба запястья)
Дисбаланс классов	до ×20

Нотация глосс: знаки РЖЯ записываются словами-метками (МАМА, ВРАЧ, ПРИЁМ). Это разбивает задачу на два этапа: распознавание знаков → перевод глосс в текст.

Общая архитектура системы

5 микросервисов:




Рис. 1 – Архитектура системы Glossa

Sequence-диаграмма (направление РЖЯ → речь)




Рис. 2 – Диаграмма РЖЯ - речь

Шаг	Компонент	P95
1	CV Service (DWPose + ST-GCN)	42 мс
2	NLP Service (Qwen2 + RAG)	525 мс *
3	TTS Service (Silero)	145 мс
4	Redis XADD/XREAD	1,1 мс
-	Итого E2E без сети	977 мс
-	Росо М5, 4G (+80 мс)	1057 мс ✓ (формально)

Таб. 1 – Критический путь (P95, эксперимент 08, режим dry-run)

Извлечение ключевых точек и ST-GCN

DWPose (YOLOX-детектор + RTMPose):

- Двухэтапная схема: YOLOX находит bbox человека → RTMPose оценивает 133 точки COCO-WholeBody → ремар в 75 узлов (33 тела + 21+21 кисти) × 3 = 225 признаков/кадр
- Нормализация: вычитание центра бёдер (точки 11,12) → деление на ширину плеч (точки 5,6)
- Производительность: ~15–20 FPS на CPU при 640×480 (ниже MediaPipe из-за отдельного детектора, но устойчивее к быстрым движениям кистей) ST-GCN с адаптивной матрицей смежности:
- 9 блоков: $GCN (Z = \hat{A} \cdot X \cdot W)$ + TCN (свёртка 1×9) + BN + ReLU + Residual
- Каналы: $64 \rightarrow 64 \rightarrow 64 \rightarrow 128 \rightarrow 128 \rightarrow 128 \rightarrow 256 \rightarrow 256 \rightarrow 256$
- $\hat{A} = A_{fixed} + A_{learn}$, граф построен по топологии COCO-WholeBody (а не BlazePose, как в MediaPipe)
- Global Average Pooling → FC(1000) → Softmax




Рис. 3 – Архитектура ST-GCN

Алгоритм скользящего окна

Параметры (обоснованы экспериментом 02; ближайшая точка сетки к реальному конфигу):

Параметр	Значение	Смысл
W — длина окна	32 кадра	Соответствует длине обучающей последовательности $T=32$
S — шаг	15 кадров	~53% перекрытие
θ — порог	0,7	Отсечение ненадёжных предсказаний
Accuracy	0,82	Грид-точка w30_s15, ближайшая к реальному $W=32/S=15$
P95 задержка	28 мс	Укладывается в SLO ≤ 50 мс
PPS	2,9 жеста/с	При 25 FPS видеопотоке

Таб. 2 – Параметры скользящего окна

Алгоритм скользящего окна (эксперимент 02: $W=32$, $S=15$, $\theta=0.7$)




Рис. 4 – Алгоритм скользящего окна

NLP: LLM + LoRA + RAG

Выбранная модель: Qwen2-1.5B-Instruct (Alibaba, 2024)

- 1,5 млрд параметров, контекст 32 768 токенов, поддержка русского языка

LoRA (Low-Rank Adaptation):

- $\Delta W = B \cdot A$, $r = 16$, $\alpha = 32$, применяется к Q, K, V, O матрицам внимания
- QLoRA (4-bit): потребление памяти 3,1 ГБ → **0,9 ГБ**

RAG (Retrieval-Augmented Generation)(опционален, требует доменного глоссария):

- BGE-M3 → Qdrant (dense search, K=5) → доменный фильтр → системный промпт

Результаты (эксперимент 06, dry-run):

Условие	BLEU-4	ROUGE-L	Recall мед.	Recall банк.
LLM без RAG	0,32	0,58	0,61	0,64
LLM + RAG общий	0,40	0,65	0,74	0,72
LLM + RAG доменный	0,44	0,69	0,88	0,90

Таб. 3 – Сравнение NLP-метрик

NLP: LLM + LoRA + RAG




Рис. 5 – NLP: LLM + LoRA + RAG

Эксперименты: обоснование архитектурных решений

Эксп. 01 — Выбор архитектуры классификатора:

Модель	Размер, МБ	P95, мс	PPS (CPU)	SLO
ST-GCN + ONNX + OpenVINO	3,5	42	23,8	✓
S3D (SberDevices)	87	95	10,5	✗
ResNet3D-50	120	140	7,1	✗

Эксп. 03 — Ускорение инференса:

Бэкенд	PPS	P95, мс	Ускорение	Размер, МБ
PyTorch float32	0,5	2200	×1,0	45
ONNX float32	8,1	175	×16,2	12
ONNX + OpenVINO	23,8	42	×47,6	12
ONNX INT8	28,9	35	×57,8	3,2

Эксп. 02 — Параметры скользящего окна:

W	S	Accuracy	P95, мс	PPS
16	1	0,71	18	0,4
30	15	0,82	28	2,9
64	32	0,87	44	3,2

Эксп. 04 — Выбор модели ASR:

Модель	WER	P95, мс	Размер (INT8)	SLO
Whisper tiny	0,21	98	75 МБ	✗ WER
Whisper base	0,11	210	145 МБ	✓
Whisper small	0,08	340	488 МБ	✓

Эксп. 05 — Выбор размера LLM:

Модель	BLEU-4	P95, мс	Размер	SLO
Qwen2-0.5B	0,21	195	1,1 ГБ	✗ BLEU
Qwen2-1.5B	0,38	490	3,1 ГБ	✓
Qwen2-7B	0,47	1850	14,5 ГБ	✗ задержка

Эксп. 07 — Качество синтеза речи:

Система	UTMOS	RTF	P95, мс
Silero v4	3,81	0,047	145
GigaTTS Joy	4,21	—	—
Human reference	4,47	—	—

Эксп. 08 — Сквозная задержка E2E:

Компонент	P50, мс	P95, мс
CV Service	24	42
ASR Service	165	210
NLP Service	380	540
TTS Service	115	185
E2E без сети	584	977
Росо М5, 4G	—	1057 ✓
Realme X60, 5G	—	1013 ✓
Poor 4G	—	1207 ✓

Эксп. 09 — 5-кратная кросс-валидация:

Fold	Accuracy	F1-macro	ECE
1	0,871	0,854	0,042
2	0,868	0,851	0,045
3	0,876	0,860	0,039
4	0,863	0,846	0,048
5	0,872	0,855	0,041
Mean ± std	0,870 ± 0,005	0,853 ± 0,005	0,043 ± 0,003

DVC-пайплайн и MLOps




Рис. 6 – MLOps инфраструктура

[illegible]

15

Заключение

Результат	Значение
Микросервисов разработано	5
Классов жестов в словаре	1000
Топ-1 ассурасу ST-GCN (реально обучено)	38,2% (SLO $\geq 0,90$ X)
Ускорение инференса vs PyTorch	$\times 47,6$ (ONNX+OpenVINO, не зависит от точности)
P95 задержки CV+классификация	42 мс (SLO ≤ 50 мс ✓, скоростной бенчмарк)
BLEU-4 перевода (dry-run, RAG опц.)	0,44 (SLO $\geq 0,35$ ✓, dry-run оценка)
WER модели ASR (литературная оценка)	0,11 (SLO $\leq 0,15$ ✓, не измерено на своих данных)
E2E P95 (dry-run проекция)	1057 мс — РЕАЛЬНО измеренная NLP-латентность на CPU $\sim 60\,000$ мс, SLO ≤ 2000 мс не выполняется
Строк кода	$\sim 12\,000$
Покрытие тестами	73%

Направления развития:

- Переобучение ST-GCN на полном корпусе с T=64, усиленной регуляризацией
- Оптимизация NLP-инференса для реального соответствия SLO задержки (квантование INT8/INT4, батчинг, либо GPU в production)
- Мобильное приложение iOS / Android
- Расфширение доменных словарей

Ссылка на GitHub репозиторий

